

Agente Conversacional AeroNova

Servicio serverless de atención a agentes de mostrador: ReAct sobre LangGraph, RAG normativo, memoria conversacional en DynamoDB y despliegue reproducible con Terraform.

Jesús Antonio Arredondo
31 de agosto de 2026


api_url · ui_url
Requisitos: PRD v2.7 · Harness: Agents.md · Región: us-east-1

50/50	331	≈ 0,40
GOLDEN DATASET — 8 UMBRALES	PRUEBAS UNITARIAS EN VERDE	USD/MES DE INFRAESTRUCTURA AWS

Este documento reúne los siete puntos del entregable de §16: URL del servicio activo, terraform plan limpio, evidencia de aceptación, contratos de datos publicados, evidencia de linaje, guía de uso operativa y esta documentación técnica. El código vive en la rama feat/aeronova-implementacion ; la imagen desplegada es aeronova-agent:d4ffb13 (arm64).

1 Arquitectura del servicio

Una sola función Lambda (imagen de contenedor, arm64, 2 GB, concurrencia reservada 20) detrás de API Gateway REST con autenticación x-api-key y un Usage Plan que fija el techo de gasto. La interfaz es estática en S3, servida por CloudFront con Origin Access Control. El índice vectorial se descarga a /tmp en el arranque y se refresca en caliente cuando cambia el puntero CURRENT .



PLANO DE DATOS EN EJECUCIÓN


- aeronova-flights — PK `codigo_vuelo` ; GSI `origen-index` , `destino-index`
- aeronova-reservations — PK `pnr` ; GSI `codigo_vuelo-index`
- aeronova-memory — PK `session_id` + SK `sk` ; TTL en `expires_at` (segundos)
- LanceDB `politicas` — 1024 dim, coseno, `top_k=4` , umbral 0,35
- Bedrock `amazon.titan-embed-text-v2:0` — solo embeddings
- Anthropic `claude-sonnet-5` — sin sampling, `thinking` desactivado, caché de prompt TTL 1 h

OPERACIÓN Y GUARDARRAÍLES

- EventBridge `rate(5 minutes)` → `{"warmup": true}` : refresca el índice y precalienta el cliente LLM
- 10 alarmas CloudWatch → SNS por correo (errores, p95, throttles, coste diario, filtro de salida, inyección, edad de `CURRENT` , cuarentena, truncados)
- AWS Budgets 20 USD con alertas 50/80/100 %
- Cortacircuitos de coste por sesión:
`SESSION_COST_LIMIT_USD = 0,75` → 429
`SESSION_BUDGET_EXCEEDED`
- Secretos en SSM `SecureString`; nunca en variables de entorno ni en Git

2 Flujo medallion de datos (§6A.2)


Un único generador sintético alimenta las tres familias de datos. Bronze es crudo e inmutable, particionado por fecha de ingesta. La promoción a Silver aplica el contrato y las expectativas E-01...E-09; si una expectativa de tipo *ABORTA* falla, el pipeline se detiene y el sistema degrada a «datos de ayer», nunca a «datos rotos». Gold se reconstruye **íntegramente** desde Silver.



Expectativa	Acción al fallar	Resultado
E-01 claves duplicadas · E-02 nulos · E-03 rangos · E-05 integridad reservas→vuelos	ABORTA el lote	pass
E-04 tasa de cuarentena por lote < 2 %	ABORTA el lote	pass (1,86 %)
E-06 casi-duplicados coseno < 0,98	CUARENTENA del fragmento, el lote sigue	pass (95 en cuarentena)
E-07 dimensión 1024 y norma ≈ 1,0	ABORTA el lote	pass
E-08 salto de volumen · E-09 frescura de partición	ABORTA / avisa	pass
Prueba de humo del índice — 5 consultas, cada una con ≥ 1 resultado > 0,35	No promueve <code>CURRENT</code>	pass (5/5)

Estado del `_manifest.json` del Gold vigente (índice `v=20260831T031138Z`). E-06 se cableó en el cierre: estaba definida pero el pipeline solo ejercitaba E-07. Los 95 fragmentos en cuarentena son artículos de cierre y preámbulos repetidos entre documentos; el índice final tiene 319 chunks distintos y ningún par con coseno ≥ 0,98.

Bucle ReAct con tope de negocio de **3 rondas de herramienta** (`MAX_TOOL_ROUNDS`) y una red de seguridad de `recursion_limit = 10` . El camino máximo del grafo son 9 pasos, por debajo del límite. `finalize` persiste en línea y va directo a `END` ; la rama sin herramientas pasa por `persist_memory` .



HERRAMIENTAS REGISTRADAS — 12, TODAS DE SOLO LECTURA

- `consultar_estado_vuelo` — estado en vivo por código de vuelo
- `obtener_datos_reserva` — datos de un PNR (validación de salida R-09)
- `buscar_politicas_rag` — normativa interna, cita el título

OPERACIÓN POR AEROPUERTO (IATA)

- `vuelos_por_ciudad` — vuelos por estado
- `radar_operativo` — briefing completo
- `resumen_demoras_ciudad` — puntualidad, demoras y motivos
- `ranking_cabina` — top vuelos por mascotas y por menores
- `buscar_vuelos_ruta` — vuelos de una ruta origen→destino

OPERACIÓN POR VUELO (CÓDIGO AN)

- `pasajeros_de_vuelo` — muestra reproducible de 5
- `mascotas_por_vuelo` — recuento en cabina
- `ocupacion_vuelo` — pasaje por tipo y tarifa, equipaje
- `perfil_reservas_vuelo` — reservas por estado, canal y reembolsabilidad

DEFENSAS Y LÍMITES

- D-1...D-6: escape de `< / >` , envoltura `<dato_operativo> / <documento_recuperado>` , filtro de salida, marcado de entrada
- L-1...L-6: mensaje ≤ 1.200 car., ≤ 400 tokens est., ratio $\geq 1,5$, presupuesto de prompt 4.000, 50 turnos/sesión, ≤ 450 tokens/resultado de herramienta
- Propiedad de sesión → 403 `SESSION_FORBIDDEN` ; consultas agregadas sobre GSIs, nunca `Scan`

Dos stacks con estado local (S-03). `00-bootstrap` crea lo que la imagen necesita *antes* del primer `apply` de la aplicación, rompiendo la circularidad ECR ↔ Lambda de imagen. Ambos stacks dan `terraform plan` limpio.

00-BOOTSTRAP — 16 RECURSOS

- ECR `aeronova-agent` + lifecycle (conserva 5 imágenes)
- DynamoDB x3: `flights`, `reservations`, `memory` (PAY_PER_REQUEST, 3 GSI)
- S3 `lake` y `ui` + versionado, cifrado, bloqueo de acceso público, lifecycle
- SSM SecureString `/aeronova/anthropic_api_key`
- `random_id` para sufijos únicos

10-APP — 53 RECURSOS

- Lambda `aeronova-agent` + Log Group; 2 roles IAM + política + attachment
- API Gateway: REST API, recursos `/v1/chat`, métodos POST/OPTIONS, integraciones, deployment, stage, api-key, Usage Plan, `method_settings`, `account`
- 9 `gateway_response` con cabeceras CORS para 4XX/5XX
- CloudFront + OAC; política de bucket de UI
- 10 alarmas CloudWatch; EventBridge (regla + target); 2 permisos Lambda
- SNS (topic + suscripción por correo); AWS Budget

5 Control de costes (\$9.3)

5.1 Coste por consulta — `claude-sonnet-5`

Estrategia de caché de prompt	USD/consulta	Frente a la base
Sin caché	0,01170	—
Caché TTL 5 min	0,01001	-14,4 %
Caché TTL 1 h En uso	0,00875	-25,2 %

Precios: entrada 2,00 USD/MTok, salida 10,00 USD/MTok, escritura de caché TTL 1 h 4,00 USD/MTok, lectura de caché 0,20 USD/MTok. El TTL se elige por el hueco entre peticiones (≈ 3/hora), no por la duración de la conversación.

5.2 Infraestructura AWS — para las 2.000 consultas del techo original

Partida	USD/mes
Lambda (2.000 × 5 s × 2 GB, arm64)	0,27
Lambda — ping de calentamiento (8.640 invocaciones × 0,2 s)	0,05
DynamoDB — almacenamiento y lecturas	0,03
API Gateway REST	0,01
S3 + CloudFront	0,02
Bedrock Titan (embeddings de consulta)	< 0,01
CloudWatch Logs (retención 14 días)	0,01

Partida	USD/mes
Total recurrente AWS	≈ 0,40
Una sola vez — siembra de Gold en DynamoDB (perfil full recortado, ≈ 24.500 items)	≈ 0,03
Una sola vez — construcción del índice RAG (por reconstrucción)	< 0,01

Precios reverificados contra las tarifas públicas de us-east-1 el 31 de agosto de 2026. La siembra de una sola vez baja de los 0,24 USD del PRD (calculados sobre 190.000 items) a ≈ 0,03 USD por el recorte del perfil full de ACU-007. Gasto real acumulado del proyecto (LLM + AWS de una vez) hasta la fecha: ≈ 3 USD, frente a los 8,80 previstos y el techo duro de 17,90.

5.3 Guardarraíles de gasto (\$9.5)

#	Control	Qué impide
G-1	Cuota del Usage Plan, period = MONTH	Techo estructural del gasto de LLM. Elevada a 10.000/mes (ACU-008); a ese nivel deja de ser el control vinculante
G-2	Límite de gasto del workspace de Anthropic	Cubre el gasto que no pasa por API Gateway (scripts locales, pytest)
G-3	AWS Budgets 20 USD, alertas 50/80/100 %	Barrera dura del lado AWS. No se modifica
G-4	Concurrencia reservada 20 + alarma de coste diario	Un bucle o una prueba mal lanzada

Tras ACU-008, la barrera dura efectiva es G-3 (AWS Budget de 20 USD). El gasto real va dos órdenes de magnitud por debajo.

6

Datos sintéticos y linaje

Dataset	Bronze	Silver	Cuarentena	Casos borde incluidos
Vuelos	9.000	9.000	0	7 estados, demoras con motivo, puertas nulas
Reservas	15.002	14.552	450 (3,0 %)	Ruta A: contract_* rechazadas en la puerta; 12 de ruta B inyectadas en Gold; 2 fixtures de inyección (INJ001/INJ002)
Corpus normativo	150	150 · 414 chunks	95 chunks (E-06)	Referencias cruzadas entre políticas; 2 documentos de accesibilidad con inyección embebida (POL-ACC-019/020)

Cifras del _manifest.json del Gold vigente. Cada valor normativo es **canónico por regla**: todos los documentos de una categoría afirman la misma cifra para la misma norma, de modo que el RAG nunca recupera fragmentos que se contradigan. El índice se construye con reembebito incremental: solo se paga Titan por los documentos cuyo checksum cambió.

Muestra — <code>silver/reservations/reservations.parquet</code>					
pnr	codigo_vuelo	estado	clase_tarifa	canal_compra	pax
(ejemplo)	AN6582	CONFIRMADA	FLEX	AGENCIA	5
RB0000 (ruta B)	AN400	CONFIRMADA	FLEX	WEB	0

7

Evidencia de aceptación

7.1 Golden dataset (§8.3) — 50 casos, 14 familias

Umbral	Exigido	Obtenido
Precisión de selección de herramienta	≥ 90 %	100 %
<code>hallucination_*</code> — no inventa datos ausentes	100 %	4/4
<code>memory_*</code> — mantiene contexto entre turnos	100 %	4/4
<code>injection_*</code> (4 familias) — ignora instrucciones en datos/documentos	100 %	7/7
<code>abuse_*</code> — rechaza antes del modelo, sin coste	100 %	3/3
<code>anomalia_*</code> — reserva corrupta, sin HTTP 5xx	100 %	4/4
<code>contract_*</code> — datos que violan el contrato en runtime	100 %	3/3
<code>operacion_*</code> — selección correcta entre las 12 herramientas	—	9/9
<code>finish_reason = max_rounds</code>	≤ 10 %	0 %
E-01...E-09 en el <code>_manifest.json</code> del Gold vigente	pass	9/9

Corrida completa (`--full --no-cache`) contra el endpoint desplegado con la imagen `d4ffb13` : 54 consultas, coste real 0,28 USD. El runner cachea por *huella* (hash de `prompts.py` + registro de herramientas + modelo); nunca se cierra con `--smoke` (R-17). Los 50 casos cubren las 13 familias de §8.2 más `operacion_*` (9 casos: las 12 herramientas de operación).

7.2 Prueba de carga (§8.4) — con la salvedad del hallazgo 29

Métrica	Valor
Sesiones (100 reales + 400 <code>dry_run</code>)	500
Duración	15,0 s
Respuestas 200	275

Métrica	Valor
Respuestas encoladas / rechazadas (429/503)	225
Latencia p50 / p95 / máx	243 / 9.343 / 13.107 ms
Coste real	0,259 USD
Items STATE con <code>expires_at</code> en la ventana de ~24 h (muestra 50)	23/23

Qué mide y qué no. Esta prueba verifica el *encolado* y que el TTL se escribe como atributo `expires_at` en segundos — no la desaparición del item, que depende del barrido de DynamoDB (hallazgo 29). **No es una prueba de escalado:** con la concurrencia reservada en 20 y el throttle del Usage Plan en 10/20, 500 peticiones concurrentes se rechazan en cuanto la cola se llena, y eso es exactamente lo que se espera observar. La corrida canónica es la del 2026-08-30; el reintento tras restaurar la concurrencia a 20 no cambia la conclusión.

8

Desviaciones registradas frente al PRD

- **ACU-007 — el perfil `full` capa los vuelos a 9.000.** Contradicción del PRD (I-15): \$7.2 pide 90.000 vuelos pero \$5.4 fija la clave primaria como `^AN\d{3,4}$`, que solo da 9.900 códigos únicos. Además, 3 % de ruta A sobre 100.000 reservas con 9.000 vuelos incumple el 2 % de E-04. Resuelto capando `full` a 9.000 vuelos / 15.000 reservas; el corpus (150) no cambia. La diferencia de coste es < 0,25 USD.
- **ACU-008 — cuota G-1 elevada de 2.000 a 10.000/mes.** El tráfico del cierre (golden completo ×3, prueba de carga ×3, despliegue y demo) agotó las 2.000 estructurales; \$9.5 ya advierte de que `pytest tests/golden` y la carga cuentan contra G-1. A 10.000, G-1 deja de ser el control de coste vinculante y pasa a serlo el AWS Budget de 20 USD, que no se toca.
- **ACU-005 — concurrencia reservada de la Lambda.** Se desplegó temporalmente sin concurrencia reservada porque la cuenta arrancaba con el límite global de concurrencia en 10. *Resuelto:* Service Quotas lo subió a 1.000 y `reserved_concurrent_executions = 20` quedó restaurado.
- **E-06 se cableó en el cierre.** La expectativa de casi-duplicados estaba definida pero el pipeline RAG solo ejercitaba E-07. Ahora se ejecuta con semántica de cuarentena; no cambia el comportamiento en runtime, solo cierra un hueco de la Definición de Terminado.

Definición de Terminado (§16): despliegue reproducible desde el runbook de §13 ✓ · pipeline medallion de extremo a extremo con todas las expectativas en `pass` y Silver/Gold reconstruidos desde Bronze ✓ · suite dorada cumpliendo todos los umbrales ✓ · `terraform plan` limpio en ambos stacks ✓ · ningún secreto en Git ni en CloudWatch (redacción vía `mask_pnr / redact_message` y filtro de salida D-5) ✓. El `terraform destroy` de teardown queda pendiente de la decisión de cierre de la demo; los comandos están en ACU-004 y ACU-007.